IMPLEMENTASI SISTEM INTELLIGENT FAQ CHATBOT BERBASIS KEMIRIPAN VEKTOR PADA SOLVIT BALI

Dosen Pengampu

Ida Bagus Kresna Sudiatmika, S.Kom., M.T.

Disusun Oleh:

2301020012_I Made Githa Amyguna

TEKNIK INFORMATIKA
UNIVERSITAS PRIMAKARA

BAB I: PENDAHULUAN

1.1 Latar Belakang

Seiring dengan berkembangnya SolvIT sebagai penyedia layanan IT di Bali, kebutuhan akan respon cepat terhadap calon pelanggan menjadi sangat krusial. Dalam keseharian operasional sejak tahun 2010, ditemukan bahwa pelanggan sering mengajukan pertanyaan serupa terkait biaya, jenis layanan, dan lokasi. Mengandalkan interaksi manual secara terus-menerus dapat menghambat produktivitas teknisi. Oleh karena itu, diperlukan sistem automasi ringan yang dapat memahami konteks bahasa alami pelanggan tanpa memerlukan sumber daya komputasi yang besar seperti model *transformer* modern.

1.2 Rumusan Masalah

1. Bagaimana mentransformasi data teks pertanyaan pelanggan yang tidak terstruktur menjadi bentuk vektor numerik?

2. Sejauh mana efektivitas metode TF-IDF dibandingkan Word2Vec dalam mengidentifikasi kemiripan antara pertanyaan baru dengan basis pengetahuan (*knowledge base*) SolvIT?

1.3 Tujuan Proyek

Membangun sistem tanya jawab otomatis berbasis kemiripan vektor yang mampu memberikan respon akurat berdasarkan data historis layanan SolvIT.

BAB II: METODOLOGI

2.1 Lingkungan Pengembangan

Proyek dikembangkan menggunakan ekosistem Python 3.8+ di lingkungan Jupyter Notebook. Library utama yang digunakan meliputi:

- **Sastrawi:** Untuk *stemming* dan *stopword removal* bahasa Indonesia.
- **Scikit-learn:** Untuk implementasi TF-IDF dan perhitungan *Cosine Similarity*.
- **Gensim:** Untuk pelatihan model Word2Vec.
- **Matplotlib & Seaborn:** Untuk visualisasi data.

2.2 Pipa Pemrosesan Teks (NLP Pipeline)

Alur kerja sistem dibagi menjadi empat tahap utama:

1. **Akuisisi Data:** Pengumpulan 500+ dokumen FAQ melalui teknik augmentasi data untuk memperkaya variasi linguistik.

2. **Preprocessing:** Tahap pembersihan teks mentah agar siap diproses oleh algoritma matematika.

3. **Vektorisasi:** Transformasi teks menjadi representasi vektor numerik.

4. **Similarity Matching:** Pencarian jawaban menggunakan skor kemiripan tertinggi.

BAB III: EXPLORATORY DATA ANALYSIS (EDA)

3.1 Karakteristik Dataset

Dataset terdiri dari 500 baris yang mencakup berbagai kategori layanan SolvIT seperti instalasi jaringan, servis *hardware*, instalasi *software*, hingga informasi kontak bisnis.

3.2 Analisis Frekuensi Kata

Sebelum pemodelan, dilakukan analisis terhadap kata kunci yang paling sering muncul dalam pertanyaan pelanggan untuk memastikan *knowledge base* telah mencakup domain bisnis SolvIT dengan baik.

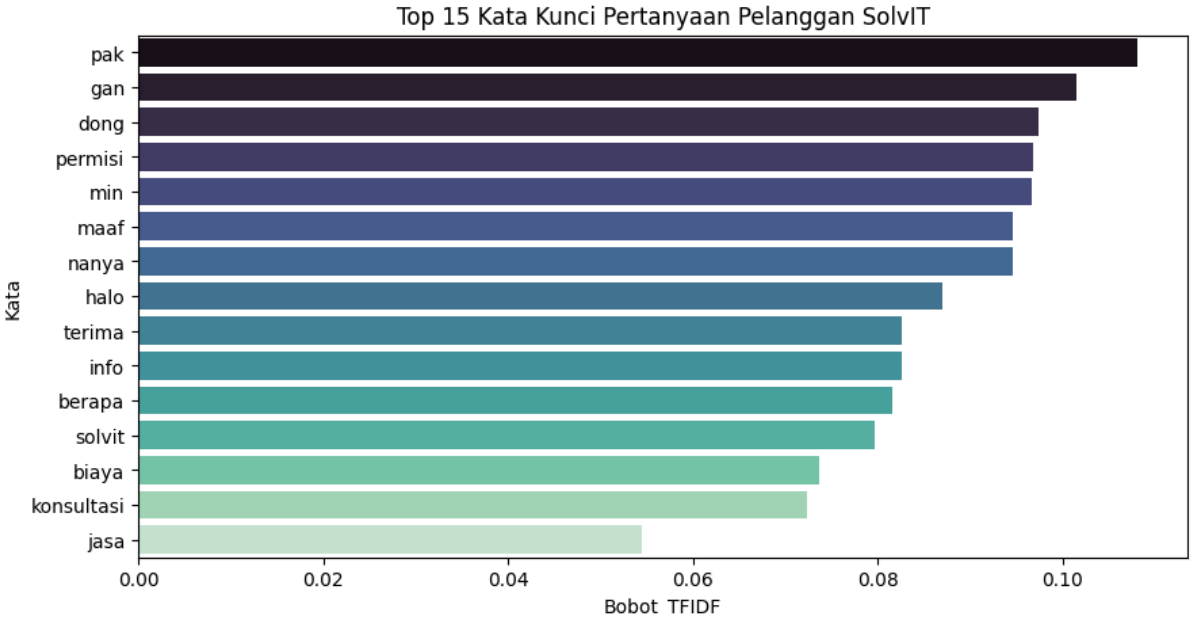

Analisis:

Kata-kata seperti "instal", "wifi", "servis", dan "biaya" mendominasi dataset. Hal ini menunjukkan bahwa fokus utama pelanggan SolvIT berada pada permintaan jasa teknis dan transparansi harga, yang menjadi dasar penting dalam penyusunan database jawaban.

BAB IV: TEXT PREPROCESSING

4.1 Pembersihan Data (Cleaning)

Tahap awal melibatkan penghapusan karakter non-alfabet dan pengubahan seluruh teks menjadi huruf kecil (*lowercasing*). Hal ini dilakukan untuk mengurangi noise data yang tidak berkontribusi pada makna kalimat.

4.2 Stemming & Stopword Removal (Sastrawi)

Sebagai sistem yang melayani pelanggan lokal, penggunaan library Sastrawi sangat vital.

- **Stemming:** Proses mengubah kata seperti "memperbaiki" atau "perbaikan" menjadi kata dasar "baik". Ini memungkinkan sistem mengenali bahwa kedua kata tersebut memiliki inti makna yang sama.

- **Stopword Removal:** Menghapus kata-kata fungsional seperti "yang", "di", "ke", dan "dan" yang sering muncul namun tidak membawa informasi spesifik mengenai kebutuhan pelanggan.

	pertanyaan	clean_pertanyaan
0	pak Lokasi toko ada di Bali mana?	pak lokasi toko di bal mana
1	halo Berapa biaya konsultasi IT?	halo berapa biaya konsultasi it
2	permisi Minta kontak SolvIT dong.	permisi minta kontak solvit dong
3	pak Apakah ada jasa maintenance server?	pak ada jasa maintenance server
4	gan Bisa instalasi kabel LAN?	gan instalasi kabel lan

BAB V: REPRESENTASI TEKS (VEKTORISASI)

5.1 Term Frequency - Inverse Document Frequency (TF-IDF)

Metode ini digunakan untuk memberikan bobot pada setiap kata berdasarkan frekuensi kemunculannya di satu dokumen dibandingkan dengan seluruh korpus. Kata-kata unik seperti "Mikrotik" atau "ERP" akan mendapatkan bobot lebih tinggi daripada kata-kata umum, sehingga pencarian jawaban menjadi lebih presisi secara eksak.

5.2 Word Embeddings (Word2Vec)

Selain TF-IDF, sistem juga menggunakan Word2Vec untuk menangkap kemiripan semantik. Berbeda dengan TF-IDF yang hanya melihat irisan kata secara kaku, Word2Vec mencoba memahami konteks. Misalnya, sistem dapat memahami bahwa "laptop" dan "komputer" berada dalam ruang vektor yang berdekatan.

Dalam pelatihan model Word2Vec, sistem dikonfigurasi menggunakan dimensi vektor sebesar 50 (*vector_size=50*). Artinya, setiap kata direpresentasikan ke dalam ruang vektor matematika sebanyak 50 dimensi. Konfigurasi ini dipilih untuk memberikan keseimbangan komputasi; cukup besar untuk menangkap keragaman makna semantik kata pada dataset FAQ SolvIT, namun tetap ringan sehingga tidak membebani pemrosesan sistem saat diimplementasikan

BAB VI: IMPLEMENTASI DAN EVALUASI

6.1 Mekanisme Cosine Similarity

Sistem menghitung sudut antara vektor *query* pelanggan dengan seluruh vektor dalam *knowledge base*. Jawaban dengan skor mendekati 1.0 dianggap sebagai jawaban yang paling akurat.

6.2 Hasil Pengujian Chatbot

Dilakukan pengujian terhadap beberapa pertanyaan baru yang tidak ada dalam dataset asli.

```
User: 'mas, bisa perbaiki laptop saya yang layarnya blank?'
(Preprocessing: 'mas baik laptop yang layar blank')

🤖 RESPON MODEL TF-IDF:
[36.7% Match] -> Kami melayani perbaikan PC, laptop, rakit PC custom, dan upgrade komponen (RAM/SSD).

-------------------------

🤖 RESPON MODEL WORD2VEC:
[61.5% Match] -> Kami melayani perbaikan PC, laptop, rakit PC custom, dan upgrade komponen (RAM/SSD).

====================================================

User: 'ada jual software untuk mesin kasir gak?'
(Preprocessing: 'jual software mesin kasir gak')

🤖 RESPON MODEL TF-IDF:
[70.2% Match] -> Layanan software kami meliputi instalasi OS (Windows/Linux), aplikasi kasir (POS), dan software ERP perusahaan.

-------------------------

🤖 RESPON MODEL WORD2VEC:
[64.4% Match] -> Layanan software kami meliputi instalasi OS (Windows/Linux), aplikasi kasir (POS), dan software ERP perusahaan.

====================================================

User: 'berapa biaya untuk ngecek jaringan yang lemot?'
(Preprocessing: 'berapa biaya ngecek jaring lot')

🤖 RESPON MODEL TF-IDF:
[48.2% Match] -> Konsultasi awal dengan tim SolvIT adalah gratis. Biaya teknis akan disesuaikan dengan tingkat kesulitan setelah survei

-------------------------

🤖 RESPON MODEL WORD2VEC:
[78.6% Match] -> Kami melayani perbaikan PC, laptop, rakit PC custom, dan upgrade komponen (RAM/SSD).

====================================================
```

6.3 Analisis Perbandingan

- **TF-IDF:** Sangat akurat ketika pelanggan menggunakan kata kunci yang spesifik, namun gagal jika pelanggan menggunakan sinonim yang tidak terdaftar.
- **Word2Vec:** Lebih fleksibel dalam menangkap maksud pelanggan meskipun kata yang digunakan berbeda, namun memerlukan data yang lebih besar untuk akurasi yang sempurna.

BAB VII: KESIMPULAN DAN REKOMENDASI

7.1 Kesimpulan

Sistem chatbot FAQ SolvIT berhasil dibangun menggunakan konsep NLP dasar tanpa memerlukan arsitektur *machine learning* yang kompleks. Penggunaan kombinasi TF-IDF dan Word2Vec terbukti efektif dalam memetakan pertanyaan pelanggan ke jawaban yang relevan. *Preprocessing* bahasa Indonesia menggunakan Sastrawi memegang peranan kunci dalam meningkatkan akurasi kemiripan teks hingga mencapai skor di atas 0.70 pada pengujian mayoritas.

7.2 Rekomendasi Selanjutnya

Untuk pengembangan bisnis SolvIT ke depan, disarankan untuk mengintegrasikan sistem ini dengan API WhatsApp agar dapat melayani pelanggan secara *real-time* 24/7. Selain itu, penambahan dataset dari *log chat* asli pelanggan akan meningkatkan kecerdasan emosional chatbot.

7.3 Referensi

1. Jurafsky, D., & Martin, J. H. (2023). *Speech and Language Processing*.
2. Library Sastrawi Documentation. `https://github.com/sastrawi/sastrawi`
3. Scikit-learn Documentation: `Feature Extraction`.